

Анализ кредитного риска: Часть 1

Формулировка исследовательского вопроса и описание данных

Собакин Георгий

6 октября 2026 г.

Содержание

1	Исследовательский вопрос	3
2	Описание данных и метод выборки	3
3	Потенциальные ошибки	5
4	Список ключевых переменных (кодебук)	7
	Заключение	7

1 Исследовательский вопрос

Основной вопрос: *Влияет ли финансовое положение заёмщика на сумму выдаваемого кредита и уровень кредитного риска?*

Этот вопрос имеет прямое практическое значение для банковского сектора: понимание факторов, определяющих кредитный риск, позволяет разрабатывать более точные скоринговые модели и оптимизировать политику одобрения кредитов.

Уточняющие подвопросы

Для детализации основного вопроса выделены следующие подвопросы:

1. Различаются ли суммы кредитов у заёмщиков с разным финансовым положением (статус чекового и сберегательного счетов)?
2. Связан ли статус финансового положения с кредитным риском (вероятностью дефолта)?
3. Какие финансовые переменные наиболее информативны для прогнозирования кредитного риска?

Ответы на эти вопросы будут получены в ходе последующего анализа (Части 2, 3 и 4) с использованием описательных статистик, доверительных интервалов, проверки статистических гипотез и регрессионного моделирования.

2 Описание данных и метод выборки

Источник данных

Для исследования используется датасет **German Credit Data**, доступный в репозитории UCI Machine Learning Repository [1]. Этот датасет был собран исследователем Hans Hofmann в 1994 году и содержит информацию о 1000 кредитных заявках, поданных в немецкий банк в период с 1970 по 1975 год.

Характеристики датасета:

- **Объём выборки:** 1000 наблюдений (кредитных заявок)
- **Количество переменных:** 21 (20 атрибутов + 1 целевая переменная)
- **Типы данных:** количественные (7 переменных), категориальные (14 переменных)
- **Пропущенные значения:** отсутствуют
- **Период сбора:** 1970–1975 годы
- **География:** Германия

Метод выборки

Датасет German Credit Data представляет собой **выборку по удобству (convenience sampling)** — не вероятностную выборку из генеральной совокупности всех заёмщиков Германии.

Обоснование выбора метода:

Исследователи использовали доступные данные реального немецкого банка за определённый период. Такой подход имеет следующие преимущества:

1. **Реалистичность данных:** это не синтетические или смоделированные данные, а реальные кредитные заявки с фактическими исходами (дефолт/недефолт). Это обеспечивает высокую экологическую валидность — результаты можно интерпретировать в контексте реальной банковской практики.
2. **Полнота информации:** датасет содержит широкий набор атрибутов (финансовые, демографические, социальные), что позволяет проводить многомерный анализ и выявлять сложные взаимосвязи.
3. **Доступность и воспроизводимость:** данные открыты и свободно доступны, что позволяет другим исследователям воспроизвести анализ и сравнить результаты. Это критически важно для научной и прикладной практики.
4. **Широкая используемость:** German Credit Data является одним из наиболее цитируемых датасетов в исследованиях кредитного скоринга и машинного обучения. На его основе опубликованы сотни научных статей, что подтверждает его ценность как бенчмарка для сравнения методов.

Почему не вероятностная выборка?

Для построения репрезентативной вероятностной выборки всех заёмщиков страны потребовалось бы:

- Получить доступ к данным всех банков (что невозможно из-за банковской тайны и коммерческой конфиденциальности)
- Провести стратификацию по регионам, доходам, возрастным группам
- Обеспечить случайный отбор заявок внутри каждого страта
- Затратить значительные ресурсы на сбор и обработку данных

В условиях ограниченных ресурсов и отсутствия доступа к полным банковским данным использование выборки по удобству — разумный компромисс между реалистичностью и практической осуществимостью.

Ограничения метода выборки

Несмотря на ценность данных, необходимо признать следующие ограничения:

- **Специфичность банка:** данные собраны в одном конкретном банке, который может иметь специфическую клиентуру (определённый регион, доходный уровень, возрастную структуру). Результаты могут не обобщаться на другие банки или страны.

- **Временное смещение:** данные собраны в 1970-х годах, когда экономические условия, банковское регулирование и потребительское поведение существенно отличались от современных.
- **Отсутствие стратификации:** выборка не стратифицирована по ключевым демографическим признакам, что может привести к недопредставленности некоторых групп.

Эти ограничения будут учтены при интерпретации результатов в последующих частях исследования.

3 Потенциальные ошибки

Выборочные ошибки

Определение: Выборочная ошибка — это разница между оценкой параметра на основе выборки и его истинным значением в генеральной совокупности.

Конкретно для данного датасета:

1. **Ограниченный объём выборки:** 1000 наблюдений — это относительно небольшая выборка. Это может привести к тому, что некоторые редкие категории (например, заёмщики с экстремально высоким доходом) будут недопредставлены.
2. **Специфичность банка:** если банк специализировался на определённом сегменте рынка, то выборка может не отражать разнообразие всех заёмщиков страны.
3. **Временной период:** данные собраны за 5 лет (1970–1975), что может не учитывать долгосрочные циклические колебания в кредитной активности.

Влияние на результаты: Выборочные ошибки могут привести к тому, что оценки параметров (например, средняя сумма кредита, доля дефолтов) будут отличаться от истинных значений в генеральной совокупности. Однако при объёме 1000 наблюдений стандартные ошибки относительно малы, и большинство оценок должны быть достаточно точными.

Невыборочные ошибки

Определение: Невыборочные ошибки — это систематические искажения, которые возникают не из-за случайности выборки, а из-за проблем в процессе сбора данных.

Конкретно для данного датасета:

1. **Систематическая ошибка отбора (selection bias):**
 - *Проблема:* данные собраны в одном банке, который имеет специфическую политику одобрения кредитов. Если банк более строго одобрял кредиты заёмщикам с низким доходом, то в выборке будут недопредставлены рискованные заёмщики.
 - *Последствия:* оценка доли дефолтов может быть занижена, а связь между финансовым положением и кредитным риском — искажена.

2. Ошибка измерения (measurement error):

- *Проблема:* некоторые переменные могут быть измерены с ошибкой. Например, переменная кредитной истории могла классифицироваться клерком банка на основе субъективных критериев, а не строгой методологии.
- *Последствия:* это может привести к ослаблению наблюдаемых связей между переменными (аттенюация) или к ложным корреляциям.

3. Временное смещение (temporal bias):

- *Проблема:* данные собраны в 1970-х годах, когда экономические условия (инфляция, безработица, процентные ставки) и практика кредитного скоринга существенно отличались от современных.
- *Последствия:* результаты могут не обобщаться на современные условия без дополнительных корректировок.

4. Смещение из-за отсутствия ответов (non-response bias):

- *Проблема:* в датасете отсутствуют пропущенные значения, что может означать, что “неудобные” случаи (например, заёмщики с неполной информацией) были отфильтрованы на этапе первичной обработки данных.
- *Последствия:* выборка может быть более “чистой”, чем реальная генеральная совокупность, что приводит к заниженной оценке неопределённости.

5. Смещение выжившего (survivorship bias):

- *Проблема:* данные включают только заёмщиков, которые *получили* кредит. Заёмщики, которым было отказано, не включены в выборку.
- *Последствия:* мы не можем оценить, какие характеристики приводят к отказу в кредите, и как это влияет на наблюдаемые связи в одобренных заявках.

Влияние ошибок на результаты

Перечисленные ошибки могут привести к следующим смещениям:

- **Занижение доли дефолтов:** из-за строгой первичной фильтрации банком.
- **Искажение связей:** ошибки измерения могут ослабить наблюдаемые корреляции между финансовым положением и кредитным риском.
- **Ограниченная обобщаемость:** результаты требуют осторожной экстраполяции на современные реалии.

Эти ограничения будут строго учитываться при интерпретации результатов в Части 2, Части 3 и Части 4 данного исследования.

4 Список ключевых переменных (кодебук)

В таблице 1 приведён список ключевых переменных датасета с указанием типа, описания и роли в последующем анализе.

Переменная	Тип	Описание	Роль в анализе
credit_amount	Колич.	Сумма кредита в немецких марках (DM)	Зависимая переменная
duration	Колич.	Срок кредита в месяцах	Объясняющая переменная
credit_risk	Бинарная	Кредитный риск: хороший, плохой	Целевая переменная
status_checking	Катег.	Статус чекового счёта: < 0 DM, $0 \leq X < 200$ DM, ≥ 200 DM, отсутствует	Категориальный предиктор
savings_status	Катег.	Статус сберегательного счёта: < 100 , $100-500$, $500-1000$, ≥ 1000 , неизвестно	Категориальный предиктор
own_telephone	Бинарная	Наличие телефона: да, нет	Бинарный маркер

Таблица 1: Ключевые переменные датасета German Credit Data

Заключение

В первой части исследования были сформулированы исследовательский вопрос и описаны данные для последующего анализа.

Ключевые выводы:

1. **Исследовательский вопрос** сформулирован чётко и измеримо, имеет прямую прикладную ценность для риск-менеджмента.
2. **Данные** представляют собой выборку по удобству из реальных банковских записей 1970-х годов. Несмотря на ограничения, датасет обладает высокой реалистичностью и широко используется в индустрии как бенчмарк.
3. **Потенциальные ошибки** (систематическая ошибка отбора, смещение выжившего, временное смещение) явно идентифицированы и будут контролироваться при интерпретации результатов.
4. **Список ключевых переменных** определён и включает 6 основных признаков, которые будут использованы для построения статистических моделей.

Результаты первой части служат методологической основой для последующего анализа во второй части (описательные статистики и визуализация), третьей части (доверительные интервалы и проверка гипотез) и четвёртой части (регрессионный анализ и диагностика моделей).

Список литературы

- [1] UCI Machine Learning Repository. German Credit Data. [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit+data\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data))
- [2] Hofmann, H. (1994). Statlog (German Credit Data) Dataset. UCI Machine Learning Repository.