

Анализ кредитного риска: Этап 2

Разведочный анализ данных (EDA) и описательная статистика

Собакин Георгий

6 октября 2026 г.

Содержание

1 Первичный анализ данных	3
2 Описательные статистики для количественных переменных	4
3 Визуализация распределений	5
4 Анализ выбросов и устойчивости статистик	7
5 Анализ по группам кредитного риска	7
6 Интерпретация результатов	8
Заключение	8

1 Первичный анализ данных

Код предобработки

```
1 library(farff)
2 library(tidyverse)
3
4 # Load data (using relative path for reproducibility)
5 file_path <- "data/german_credit.arff"
6 df_raw <- readARFF(file_path)
7
8 df <- df_raw %>%
9   rename(
10     credit_risk = class,
11     status_checking = checking_status
12   ) %>%
13   mutate(
14     credit_risk = factor(credit_risk, levels = c("good", "bad"),
15                          labels = c("Good", "Bad"))
16   )
17
18 # Primary analysis
19 str(df)
20 summary(df)
21 sum(is.na(df))
```

Объём и структура выборки

Датасет German Credit Data содержит **1000 наблюдений** (кредитных заявок) и **21 переменную**:

- **Количественные переменные:** 7 (сумма кредита, срок кредита, возраст и др.)
- **Категориальные переменные:** 14 (статус чекового счёта, кредитная история и др.)

Пропущенные значения

Проверка на пропущенные значения показала, что **пропуски отсутствуют**:

$$\sum_{i=1}^{1000} \text{is.na}(x_i) = 0$$

Это означает, что датасет полностью заполнен, что упрощает дальнейший анализ. Однако отсутствие пропусков может указывать на то, что “неудобные” случаи (заёмщики с неполной информацией) были отфильтрованы на этапе сбора данных, что является формой **смещения выжившего** (survivorship bias).

Типы переменных

Для данного этапа анализа выбраны следующие ключевые переменные:

- **credit_amount** — количественная (сумма кредита в DM)
- **duration** — количественная (срок кредита в месяцах)
- **credit_risk** — бинарная категориальная (Хороший/Плохой)

2 Описательные статистики для количественных переменных

Сумма кредита (credit_amount)

Показатель	Значение
Объём выборки (n)	1000
Среднее ($\bar{x}$)	3271,26 DM
Медиана (m)	2320,00 DM
Стандартное отклонение (s)	2822,74 DM
Минимум	250,00 DM
Максимум	18424,00 DM
1-й квартиль (Q_1)	1366,00 DM
3-й квартиль (Q_3)	3972,00 DM
Межквартильный размах (IQR)	2606,00 DM

Таблица 1: Описательные статистики для суммы кредита

Детальная интерпретация:

Среднее значение (3271 DM) **существенно превышает** медиану (2320 DM) на 41%. Это классический признак **правосторонней асимметрии** (positive skewness). Механизм формирования такой асимметрии в финансовых данных следующий:

- **Нижняя граница** распределения ограничена минимальной суммой кредита (250 DM).
- **Верхняя граница** формально не ограничена — заёмщик может запросить любую сумму при одобрении банка.
- **Большинство заёмщиков** берут кредиты на умеренные суммы (1000–4000 DM), формируя основной пик распределения.
- **Единичные крупные кредиты** (10000–18000 DM) “тянут” среднее вверх, но не влияют на медиану.

Размах (18174 DM) очень велик и превышает среднее значение в 5,6 раза, указывая на **экстремальный разброс**. Стандартное отклонение (2823 DM) составляет 86% от среднего, подтверждая высокую вариативность. Межквартильный размах (IQR = 2606 DM) показывает, что центральные 50% данных лежат в диапазоне от 1366 до 3972 DM, что является более устойчивой мерой разброса.

Срок кредита (duration)

Показатель	Значение
Объём выборки (n)	1000
Среднее ($\bar{x}$)	20,90 мес.
Медиана (m)	18,00 мес.
Стандартное отклонение (s)	12,06 мес.
Минимум	4,00 мес.
Максимум	72,00 мес.
1-й квартиль (Q_1)	12,00 мес.
3-й квартиль (Q_3)	24,00 мес.
Межквартильный размах (IQR)	12,00 мес.

Таблица 2: Описательные статистики для срока кредита

Детальная интерпретация:

Среднее (20,9 мес.) превышает медиану (18 мес.) на 16%, указывая на **правостороннюю асимметрию**, хотя и менее выраженную. Интересной особенностью является то, что квартили принимают **круглые значения**: $Q_1 = 12$ мес., $Q_3 = 24$ мес. Это не случайность — банк предлагает стандартные сроки кредитования (6, 12, 18, 24, 36, 48, 72 месяца). Это объясняет **дискретную природу** переменной duration. Медиана 18 месяцев означает, что половина кредитов выдаётся на срок до 1,5 лет.

3 Визуализация распределений

Выбор ширины бинов для гистограмм

Для выбора оптимальной ширины бинов было применено **правило Фридмана–Диакониса**:

$$h = \frac{2 \cdot \text{IQR}}{n^{1/3}}$$

Для суммы кредита это дало $h \approx 521$ DM (35 бинов), а для срока — $h \approx 2,4$ мес. (29 бинов).

Проблема: Визуальный анализ показал, что при таком количестве бинов наблюдаются **искусственные провалы**. Для суммы кредита это связано с разреженностью “хвоста”, а для срока кредита — с тем, что бины “разрывают” естественные дискретные группы (например, бин $[10; 12,4]$ захватит только значение 12).

Решение: Для более наглядного представления, соответствующего лучшим практикам визуализации данных, количество бинов было скорректировано:

- **Сумма кредита:** 18 бинов шириной ≈ 1000 DM для сглаживания шума в хвосте.
- **Срок кредита:** бины шириной 6 месяцев для учета дискретности данных.

Гистограмма суммы кредита

Рис. 1: Распределение суммы кредита (18 бинов)

Детальное описание:

1. **Выраженная правосторонняя асимметрия:** Основной пик плотности находится в диапазоне **1000–2000 DM**. Плотность быстро убывает при увеличении суммы, а “хвост” простирается до 18000 DM.
2. **Отсутствие симметрии:** Левая часть распределения крутая и короткая, правая — пологая и длинная. Это классический признак **логнормального** или **гамма-распределения**, типичного для финансовых данных.
3. **Модальность:** Распределение **унимодально** — один выраженный пик в районе 1500 DM.

Гистограмма срока кредита

Рис. 2: Распределение срока кредита (бины по 6 месяцев)

Детальное описание:

1. **Правосторонняя асимметрия:** Наибольшая плотность наблюдается для сроков **12–24** месяца.
2. **Модальная структура (мультимодальность):** В отличие от суммы кредита, распределение срока имеет **несколько локальных пиков** (6, 12, 18, 24, 48 месяцев). Это отражает отсутствие стандартных продуктов на промежуточные сроки.
3. **Дискретность:** Переменная принимает только определённые значения, что создаёт “ступенчатую” структуру.

Boxplot и Violin plot

Рис. 3: Violin plot: Сумма кредита

Обоснование преимуществ violin plot: Violin plot объединяет преимущества boxplot (пятичисловая сводка) и гистограммы (плотность распределения).

- **Для суммы кредита:** форма “скрипки” (широкая часть внизу, узкий “хвост” сверху) визуально подтверждает асимметрию и концентрацию наблюдений в нижней части.
- **Для срока кредита:** на violin plot видны **несколько “утолщений”** на разных уровнях, что подтверждает мультимодальность, которую обычный boxplot скрыл бы.

4 Анализ выбросов и устойчивости статистик

Выявление выбросов (правило $1,5 \times \text{IQR}$)

Выбросы определяются как наблюдения за пределами $[Q_1 - 1,5 \cdot \text{IQR}; Q_3 + 1,5 \cdot \text{IQR}]$.

Для суммы кредита: $[-2543; 7881]$. Количество выбросов: **72 наблюдения** (7,2% выборки). Все они выше верхней границы (крупные кредиты). Для срока кредита: $[-6; 42]$. Количество выбросов: **70 наблюдений** (7,0% выборки). Все они выше верхней границы (длительные кредиты 48–72 мес.).

Сравнение статистик до и после удаления выбросов

Показатель	До удаления	После удаления
Сумма кредита		
Среднее	3271,26	2676,26
Медиана	2320,00	2145,50
Срок кредита		
Среднее	20,90	18,67
Медиана	18,00	18,00

Таблица 3: Сравнение статистик до и после удаления выбросов

Детальный анализ устойчивости:

- **Сумма кредита:** Среднее уменьшилось на **18,2%**, а медиана — только на **7,5%**.
- **Срок кредита:** Среднее уменьшилось на **10,7%**, а медиана **не изменилась** (0%).

Вывод: Медиана является более робастной (устойчивой) статистикой, чем среднее. Для асимметричных финансовых распределений медиана лучше характеризует “типичное” значение.

5 Анализ по группам кредитного риска

Распределение кредитного риска

Выборка **несбалансирована**:

- **Хороший риск:** 700 заёмщиков (70%)
- **Плохой риск:** 300 заёмщиков (30%)

Практическое следствие: при построении моделей машинного обучения такую несбалансированность необходимо учитывать через взвешивание классов или использование метрик, устойчивых к дисбалансу (F1-score, AUC-ROC).

Сравнение групп по сумме и сроку кредита

Группа	n	Среднее (DM)	Медиана (DM)	Ст. откл.
Сумма кредита				
Хороший	700	2985	2244	2401
Плохой	300	3938	2574	3536
Срок кредита (мес.)				
Хороший	700	19,2	18	11,1
Плохой	300	24,9	24	13,3

Таблица 4: Статистики по группам риска

Ключевые наблюдения:

1. “Плохие” заёмщики берут в среднем на **32% бóльшие суммы** (3938 vs 2985 DM).
2. “Плохие” заёмщики берут кредиты на **30% бóльшие сроки** (24,9 vs 19,2 мес.).
3. **Разброс (стандартное отклонение) существенно выше** у группы “Плохого” риска, что указывает на большую неопределённость и гетерогенность этой группы.

6 Интерпретация результатов

Связь с исследовательским вопросом

Основной вопрос: *“Влияет ли финансовое положение заёмщика на сумму выдаваемого кредита и уровень кредитного риска?”*

Проведённый EDA показывает:

- **Да, кредитный риск связан с суммой и сроком.** Рискованные заёмщики систематически берут бóльшие суммы на бóльшие сроки. Это может указывать на то, что они пытаются покрыть финансовые трудности за счёт более крупных и длительных кредитов.
- **Разброс больше у “плохих” заёмщиков.** Это увеличивает неопределённость и риск для банка.

Для строгого подтверждения статистической значимости этих различий далее проводится проверка статистических гипотез (см. Часть 3).

Заключение

В ходе проведения разведочного анализа данных (EDA) были получены следующие ключевые выводы:

1. **Распределения сумм и сроков кредитов асимметричны** (правосторонняя асимметрия). Медиана является более устойчивой мерой центральной тенденции, чем среднее.
2. **Выбросы составляют 7–7,2% наблюдений** и существенно влияют на среднее значение, подтверждая необходимость использования робастных метрик.
3. **Кредитный риск статистически связан с параметрами кредита:** “плохие” заёмщики берут бóльшие суммы на бóльшие сроки, причём разброс у них также значительно выше.
4. **Выборка несбалансирована (70% vs 30%),** что требует особого внимания при дальнейшем моделировании.

Результаты данного этапа служат основой для последующего анализа: проверки статистических гипотез (Часть 3) и регрессионного моделирования (Часть 4).

Список литературы

- [1] UCI Machine Learning Repository. German Credit Data. [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit+data\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data))
- [2] Hofmann, H. (1994). Statlog (German Credit Data) Dataset. UCI Machine Learning Repository.