

Анализ кредитного риска: Этап 3

Статистический вывод: доверительные интервалы и проверка гипотез

Собакин Георгий

6 октября 2026 г.

Содержание

1	Методология и выбор переменных	3
2	Оценка параметров генеральной совокупности	3
3	Анализ чувствительности доверительных интервалов	4
4	Оценка доли бинарного признака	4
5	Сравнительный анализ групп по целевой переменной	5
6	Дисперсионный анализ (ANOVA)	6
7	Формальная проверка статистических гипотез	7
8	Интерпретация: статистическая vs практическая значимость	8
9	Валидация и согласованность результатов	8
10	Анализ взаимосвязей категориальных признаков (Chi-Square Test)	8
	Заключение	9

1 Методология и выбор переменных

Исследовательский вопрос: *Влияет ли финансовое положение заёмщика на сумму выдаваемого кредита и уровень кредитного риска?*

Для статистического ответа на этот вопрос выбраны следующие признаки датасета German Credit Data:

- **Сумма кредита** (*credit_amount*) — количественная переменная для оценки параметров распределения и дисперсионного анализа.
- **Кредитный риск** (*credit_risk*) — бинарная целевая переменная (Good/Bad) для стратификации выборки и оценки долей.
- **Статус чекового счёта** (*status_checking*) — категориальная переменная (4 уровня) для оценки влияния финансового положения на сумму кредита.
- **Наличие телефона** (*own_telephone*) — бинарная переменная-маркер для оценки доли в генеральной совокупности.

2 Оценка параметров генеральной совокупности

Код оценки

```
1 # 95% CI for mean credit amount
2 amounts <- df %>% drop_na(credit_amount) %>% pull(credit_amount)
3 n <- length(amounts)
4 mean_val <- mean(amounts)
5 sd_val <- sd(amounts)
6 se_val <- sd_val / sqrt(n)
7 t_critical <- qt(1 - 0.05/2, df = n - 1)
8 ci_lower <- mean_val - t_critical * se_val
9 ci_upper <- mean_val + t_critical * se_val
10 ci_width <- ci_upper - ci_lower
```

Результаты

Для переменной **Сумма кредита** рассчитаны следующие метрики:

- Объём выборки: $n = 1000$
- Выборочное среднее: $\bar{x} = 3271,26$ DM
- Выборочное стандартное отклонение: $s = 2822,74$ DM
- Стандартная ошибка среднего: $SE = \frac{s}{\sqrt{n}} = 89,26$

Критическое значение t -распределения Стьюдента при $\alpha = 0,05$ и $df = 999$:

$$t_{0,025; 999} \approx 1,9623$$

95% доверительный интервал для генерального среднего μ :

$$\bar{x} \pm t_{\alpha/2; df} \cdot SE = 3271,26 \pm 1,9623 \cdot 89,26 \Rightarrow [3096,09; 3446,42]$$

Ширина интервала составляет 350,33 ДМ ($\approx 10,7\%$ от среднего), что указывает на высокую точность оценки благодаря большому объёму выборки ($SE \propto 1/\sqrt{n}$).

Обоснование выбора t -распределения: Используется t -распределение, а не нормальное Z , поскольку генеральное стандартное отклонение σ неизвестно и оценивается по выборке через s . При $n = 1000$ t -распределение асимптотически приближается к нормальному, но его использование остаётся методологически строго корректным.

3 Анализ чувствительности доверительных интервалов

Код оценки

```
1 # 90% and 99% CI
2 t_90 <- qt(1 - 0.10/2, df = n - 1)
3 ci_90_lower <- mean_val - t_90 * se_val
4 ci_90_upper <- mean_val + t_90 * se_val
5 ci_90_width <- ci_90_upper - ci_90_lower
6
7 t_99 <- qt(1 - 0.01/2, df = n - 1)
8 ci_99_lower <- mean_val - t_99 * se_val
9 ci_99_upper <- mean_val + t_99 * se_val
10 ci_99_width <- ci_99_upper - ci_99_lower
```

Результаты

Для той же переменной построены интервалы при трёх уровнях доверия:

Уровень доверия	$t_{\alpha/2; 999}$	Границы ДИ	Ширина
90%	1,6464	[3124,30; 3418,22]	293,92
95%	1,9623	[3096,09; 3446,42]	350,33
99%	2,5808	[3040,89; 3501,62]	460,73

Интерпретация: Переход от 90% к 99% уровню доверия увеличивает ширину интервала на 57%. Это демонстрирует фундаментальный компромисс статистического вывода: повышение уверенности в покрытии истинного параметра неизбежно снижает точность оценки (расширяет интервал).

4 Оценка доли бинарного признака

Код оценки

```

1 # 95% CI for proportion (own_telephone)
2 phone_data <- df %>% drop_na(own_telephone)
3 n_phone <- nrow(phone_data)
4 count_yes <- sum(phone_data$own_telephone == "yes")
5 p_hat <- count_yes / n_phone
6 se_prop <- sqrt(p_hat * (1 - p_hat) / n_phone)
7 z_critical <- qnorm(1 - 0.05/2)
8 ci_prop_lower <- p_hat - z_critical * se_prop
9 ci_prop_upper <- p_hat + z_critical * se_prop

```

Результаты

Для признака **Наличие телефона**:

- Выборочная доля: $\hat{p} = 0,4040$ (40,40%)
- Стандартная ошибка доли: $SE_{\hat{p}} = 0,0155$

Условия применимости нормального приближения выполнены ($n\hat{p} = 404 \geq 10$ и $n(1 - \hat{p}) = 596 \geq 10$).

95% ДИ для генеральной доли p :

$$\hat{p} \pm z_{\alpha/2} \cdot SE_{\hat{p}} = 0,4040 \pm 1,96 \cdot 0,0155 \Rightarrow [0,3736; 0,4344]$$

Бизнес-интерпретация: с уверенностью 95% истинная доля заёмщиков, имеющих собственный телефон (что в 1970-х годах являлось маркером финансовой стабильности), составляет от 37,4% до 43,4%.

5 Сравнительный анализ групп по целевой переменной

Код сравнения

```

1 # Compare means by credit_risk
2 good_group <- df %>% filter(credit_risk == "Good") %>%
3   pull(credit_amount) %>% na.omit()
4 bad_group <- df %>% filter(credit_risk == "Bad") %>%
5   pull(credit_amount) %>% na.omit()
6
7 n_good <- length(good_group)
8 mean_good <- mean(good_group)
9 sd_good <- sd(good_group)
10 se_good <- sd_good / sqrt(n_good)
11 t_good <- qt(1 - 0.05/2, df = n_good - 1)
12 ci_good_lower <- mean_good - t_good * se_good
13 ci_good_upper <- mean_good + t_good * se_good
14
15 n_bad <- length(bad_group)
16 mean_bad <- mean(bad_group)
17 sd_bad <- sd(bad_group)

```

```

18 se_bad <- sd_bad / sqrt(n_bad)
19 t_bad <- qt(1 - 0.05/2, df = n_bad - 1)
20 ci_bad_lower <- mean_bad - t_bad * se_bad
21 ci_bad_upper <- mean_bad + t_bad * se_bad
22
23 overlap <- (ci_good_lower <= ci_bad_upper) &&
24             (ci_bad_lower <= ci_good_upper)

```

Результаты

Группа	n	$\bar{x}$, DM	s , DM	95% ДИ для μ
Хороший риск	700	2985,46	2401,47	[2807,25; 3163,67]
Плохой риск	300	3938,13	3535,82	[3536,39; 4339,86]

Анализ пересечения: 95% доверительные интервалы **не пересекаются** ($3163,67 < 3536,39$), между ними имеется зазор около 373 DM. Это является сильным визуальным индикатором наличия статистически значимых различий: заёмщики с плохим кредитным риском систематически запрашивают бóльшие суммы.

6 Дисперсионный анализ (ANOVA)

Код анализа

```

1 # ANOVA: credit_amount ~ status_checking
2 print(table(df$status_checking))
3
4 boxplot(credit_amount ~ status_checking, data = df,
5         main = "Credit Amount by Checking Status",
6         xlab = "Checking Status",
7         ylab = "Credit Amount (DM)",
8         col = c("lightblue", "lightgreen", "lightyellow", "
9                 lightpink"),
10         las = 2, cex.axis = 0.8, cex.lab = 0.7)
11
12 anova_model <- aov(credit_amount ~ status_checking, data = df)
13 residuals_anova <- residuals(anova_model)
14
15 # Check assumptions
16 shapiro.test(residuals_anova)
17 bartlett.test(credit_amount ~ status_checking, data = df)
18
19 # ANOVA results
20 anova_results <- summary(anova_model)
21 print(anova_results)
22
23 # Effect size (eta-squared)
24 ss_between <- anova_results[[1]]$"Sum Sq"[1]
25 ss_total <- sum(anova_results[[1]]$"Sum Sq")
26 eta_squared <- ss_between / ss_total

```

Результаты и проверка предпосылок

Проведён однофакторный дисперсионный анализ влияния статуса чекового счёта на сумму кредита.




Рис. 1: Распределение суммы кредита по статусу чекового счёта

Проверка предпосылок:

- Нормальность остатков (Шapiro–Уилк): $W = 0,818$, $p < 0,001$ (формально нарушена).
- Гомогенность дисперсий (Бартлетт): $\chi^2 = 79,50$, $p < 0,001$ (формально нарушена).

Примечание: При $n = 1000$ ANOVA демонстрирует высокую робастность к умеренным нарушениям нормальности и гомогенности дисперсий благодаря действию Центральной Предельной Теоремы.

Результаты ANOVA:

$$F(3, 996) = 7,186, \quad p = 8,95 \times 10^{-5}$$

7 Формальная проверка статистических гипотез

Процедура проверки гипотезы о влиянии статуса счёта на сумму кредита:

1. **Гипотезы:** $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$ (средние равны) против H_1 : хотя бы одно μ_i отличается.
2. **Тип альтернативы:** двусторонняя.
3. **Уровень значимости:** $\alpha = 0,05$.

4. **Тестовая статистика:** $F = \frac{MS_{\text{between}}}{MS_{\text{within}}}$.
5. **Расчёт:** $F_{\text{набл}} = \frac{5,621 \times 10^7}{7,823 \times 10^6} = 7,186$.
6. **Критическая область:** $F_{\text{крит}}(3, 996) \approx 2,61$.
7. **Решение:** $F_{\text{набл}} > F_{\text{крит}}$ ($7,186 > 2,61$), $p\text{-value} < 0,05$. **Отвергаем H_0 .**
8. **Вывод:** Статус чекового счёта оказывает статистически значимое влияние на среднюю сумму кредита.

8 Интерпретация: статистическая vs практическая значимость

- **Статистическая значимость:** Эффект высоко достоверен ($p < 0,001$).
- **Практическая значимость (Effect Size):** $\eta^2 = \frac{SS_{\text{between}}}{SS_{\text{total}}} = 0,0212$. Статус счёта объясняет лишь **2,1%** дисперсии суммы кредита (малый эффект по Коэну).

Бизнес-применение: Несмотря на малый размер эффекта, разница в доле дефолтов между группами с отрицательным балансом (49,3%) и отсутствием счёта (11,7%) составляет 37,6 п.п. Это делает данный признак критически важным для **сегментации клиентов** и **дифференциации процентных ставок** в скоринговой модели, даже если он не является единственным предиктором.

9 Валидация и согласованность результатов

Результаты различных статистических подходов полностью согласуются:

1. **Непересечение ДИ** (Раздел 5) визуально указывает на различие групп.
2. **ANOVA** (Раздел 7) формально подтверждает это различие ($p < 0,05$).
3. Малое p -значение математически эквивалентно тому, что доверительный интервал для разности средних ($\mu_{\text{bad}} - \mu_{\text{good}}$) не содержит ноль.

10 Анализ взаимосвязей категориальных признаков (Chi-Square Test)

Код анализа

```
1 # Chi-square test: status_checking vs credit_risk
2 contingency_table <- table(df$status_checking, df$credit_risk)
3 prop_table <- prop.table(contingency_table, margin = 1) * 100
4 chi_test <- chisq.test(contingency_table)
```

```

5
6 # Cramer's V
7 n_total <- sum(contingency_table)
8 k <- min(nrow(contingency_table), ncol(contingency_table))
9 v_cramer <- sqrt(chi_test$statistic / (n_total * (k - 1)))
10
11 # Additional: savings_status vs credit_risk
12 contingency_savings <- table(df$savings_status, df$credit_risk)
13 chisq.test(contingency_savings)

```

Результаты

Таблица сопряжённости (доля плохого риска по строкам):

Статус чекового счёта	% Плохого риска (Дефолт)
Отрицательный баланс (< 0)	49,27%
Малый баланс ($0 \leq X < 200$)	39,03%
Высокий баланс (≥ 200)	22,22%
Отсутствие счёта	11,68%

Тест хи-квадрат: $\chi^2(3) = 123,72$, $p < 2,2 \times 10^{-16}$. Гипотеза о независимости отвергается.

Размер эффекта: Коэффициент V Крамера $V = 0,352$, что соответствует **умеренной связи** по шкале Коэна.

Итог: Заёмщики с отрицательным балансом имеют почти в 4 раза выше вероятность дефолта по сравнению с клиентами без счёта. Это подтверждает высокую прогностическую ценность качественных финансовых переменных в задачах кредитного скоринга.

Заключение

На третьем этапе исследования были проведены строгие статистические тесты для проверки гипотез о кредитном риске. Ключевые выводы:

1. Средняя сумма кредита оценена с высокой точностью: 95% ДИ [3096; 3446] DM.
2. Заёмщики с плохим кредитным риском берут статистически значимо бóльшие суммы (непересечение 95% ДИ).
3. Статус чекового счёта значимо влияет на сумму кредита ($p < 0,001$), однако объясняет лишь 2,1% её дисперсии (η^2), что указывает на необходимость использования многофакторных моделей.
4. Обнаружена умеренная связь ($V = 0,352$) между статусом счёта и вероятностью дефолта: клиенты с отрицательным балансом дефолтят в 4 раза чаще.

Результаты подтверждают, что финансовые переменные являются ценными предикторами, но для построения надёжной скоринговой модели их необходимо использовать в комбинации с другими признаками (что будет проверено на этапе регрессионного анализа).

Список литературы

- [1] UCI Machine Learning Repository. German Credit Data. [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit+data\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data))
- [2] Hofmann, H. (1994). Statlog (German Credit Data) Dataset. UCI Machine Learning Repository.