

Анализ кредитного риска: Этап 4

Регрессионное моделирование и диагностика

Собакин Георгий

6 октября 2026 г.

Содержание

1	Обоснование выбора переменных	3
2	Построение простой линейной регрессии	3
3	Визуализация регрессии	5
4	Анализ остатков	7
	Заключение	11

1 Обоснование выбора переменных

На предыдущем этапе исследования мы установили, что:

- Статус чекового счёта значимо влияет на сумму кредита ($p = 8,95 \times 10^{-5}$).
- Заёмщики с высоким кредитным риском берут в среднем бóльшие суммы: 3938 против 2985 DM у заёмщиков с низким риском.
- Статус чекового счёта умеренно связан с кредитным риском ($V = 0,352$).

Эти результаты указывают на то, что финансовое положение заёмщика — важный, но не единственный фактор, определяющий сумму кредита. Банк, управляя рисками, опирается и на другие характеристики кредитной заявки. Одной из ключевых таких характеристик является **срок кредита** (*duration*).

Теоретическое обоснование: срок кредита тесно связан с суммой: чем дольше срок, тем большую сумму, как правило, берёт заёмщик. Это логично — долгосрочные кредиты (например, на автомобиль или образование) обычно крупнее краткосрочных потребительских займов.

Гипотеза: срок кредита положительно связан с суммой кредита. Для проверки этой гипотезы мы строим модель простой линейной регрессии, где зависимая переменная — **сумма кредита**, а объясняющая — **срок кредита**.

Выбранные переменные:

- **Сумма кредита** (*credit_amount*) — количественная зависимая переменная, сумма кредита в немецких марках (DM).
- **Срок кредита** (*duration*) — количественная объясняющая переменная, срок кредита в месяцах.

2 Построение простой линейной регрессии

Код в R

```
1 # Descriptive statistics
2 n_obs <- nrow(df)
3 mean_amount <- mean(df$credit_amount, na.rm = TRUE)
4 sd_amount <- sd(df$credit_amount, na.rm = TRUE)
5 mean_duration <- mean(df$duration, na.rm = TRUE)
6 sd_duration <- sd(df$duration, na.rm = TRUE)
7 cor_pearson <- cor(df$credit_amount, df$duration,
8                   use = "complete.obs")
9
10 # Regression model
11 model_simple <- lm(credit_amount ~ duration, data = df)
12 summary(model_simple)
13
14 # Coefficients with confidence intervals
15 library(broom)
16 tidy_model <- tidy(model_simple, conf.int = TRUE,
```

```

17 conf.level = 0.95)
18 tidy_model

```

Описательные статистики

Переменная	Среднее	Ст. откл.	Корреляция
Сумма кредита (DM)	3271,26	2822,74	
Срок кредита (мес.)	20,90	12,06	$r = 0,625$

Таблица 1: Описательные статистики переменных ($n = 1000$)

Корреляция Пирсона между суммой и сроком кредита составляет $r = 0,625$, что указывает на умеренную положительную линейную связь.

Результаты регрессии

Уравнение модели:

$$\text{Сумма кредита}_i = \beta_0 + \beta_1 \cdot \text{Срок кредита}_i + \varepsilon_i$$

Коэффициент	Оценка	Ст. ошибка	t -статистика	p -значение	95% ДИ
Свободный член (β_0)	213,22	139,57	1,53	0,127	[-60,7; 487,1]
Срок кредита (β_1)	146,30	5,78	25,29	< 0,001	[135,0; 157,7]

Таблица 2: Результаты оценивания модели простой линейной регрессии

Показатель	Значение
R^2	0,3906
Скорректированный R^2	0,3900
F -статистика (1, 998)	639,69
p -значение (F -тест)	< 0,001
Стандартная ошибка остатков	2204,64 DM

Таблица 3: Характеристики качества модели

Интерпретация коэффициентов

Свободный член $\hat{\beta}_0 = 213,22$ ($p = 0,127$) статистически незначим на уровне 5%. Это означает, что мы не можем отвергнуть гипотезу о том, что при нулевом сроке кредита его ожидаемая сумма равна нулю — что содержательно логично: кредит с нулевым сроком не имеет смысла.

Коэффициент при сроке кредита $\hat{\beta}_1 = 146,30$ ($p < 0,001$) статистически значим. Интерпретация: *при увеличении срока кредита на 1 месяц ожидаемая сумма кредита*

возрастает в среднем на 146,30 DM при прочих равных условиях. 95% доверительный интервал [135,0; 157,7] не содержит нуля, что подтверждает надёжность оценки.

Качество модели: $R^2 = 0,3906$ означает, что срок кредита объясняет примерно 39% дисперсии суммы кредита. Это указывает на то, что срок кредита является существенным, но не единственным фактором, определяющим сумму. Оставшиеся 61% вариации объясняются другими характеристиками, не включёнными в модель.

Ответ на исследовательский вопрос

Регрессионный анализ показывает, что срок кредита является значимым предиктором суммы кредита ($p < 0,001$). Полученный результат дополняет выводы предыдущих этапов:

- Ранее мы наблюдали, что заёмщики с высоким риском берут большие суммы. Если при этом они берут кредиты на более длительные сроки, то наблюдаемый разрыв в суммах может частично объясняться различиями в сроках.
- Срок кредита и финансовое положение заёмщика (статус чекового счёта) — это разные характеристики, которые совместно влияют на сумму кредита.

Таким образом, исследовательский вопрос получает уточнённый ответ: финансовое положение заёмщика влияет на сумму кредита, но срок кредита также является важным фактором, определяющим сумму.

3 Визуализация регрессии

Код в R

```
1 p_scatter <- ggplot(df, aes(x = duration,
2                               y = credit_amount)) +
3   geom_point(alpha = 0.3, color = "steelblue", size = 1.5) +
4   geom_smooth(method = "lm", se = TRUE, color = "red",
5               linewidth = 1) +
6   labs(
7     title = "Simple linear regression",
8     x = "Duration (months)",
9     y = "Credit amount (DM)"
10  ) +
11  theme_minimal(base_size = 12)
12
13 p_scatter_risk <- ggplot(df, aes(x = duration,
14                                   y = credit_amount,
15                                   color = credit_risk)) +
16   geom_point(alpha = 0.3, size = 1.5) +
17   geom_smooth(method = "lm", se = TRUE, linewidth = 1) +
18   scale_color_manual(values = c("Good" = "steelblue",
19                                  "Bad" = "red")) +
20   theme_minimal(base_size = 12)
```

Результаты визуализации




Рис. 1: Облако точек и линия регрессии: сумма кредита vs срок кредита. Серая область — 95% доверительный интервал для линии регрессии.

Визуальная оценка качества подгонки. Линия регрессии (рис. 1) проходит через центр облака точек и отражает положительный тренд: с ростом срока кредита сумма кредита увеличивается. Однако видны следующие особенности:

- Облако точек имеет **клинообразную форму**: при малых сроках (до 20 месяцев) точки лежат плотно вокруг линии, при больших сроках (40–60 месяцев) разброс возрастает. Это означает, что для кредитов с большим сроком модель даёт менее точные предсказания.
- Значительная часть точек лежит далеко от линии: при $R^2 = 0,39$ модель объясняет менее половины вариации, что визуально подтверждается широким разбросом.




Рис. 2: Облако точек с разделением по группам кредитного риска. Синий — «Хороший» риск, красный — «Плохой» риск.

Дополнительный анализ по группам риска (рис. 2) показывает, что линии регрессии для заёмщиков с низким и высоким риском практически параллельны, но линия для группы высокого риска смещена вверх. Это согласуется с выводом предыдущего этапа о том, что такие заёмщики берут бóльшие суммы при том же сроке кредита.

4 Анализ остатков

Код в R

```
1 # Save residuals and fitted values
2 df$residuals <- residuals(model_simple)
3 df$fitted <- fitted(model_simple)
4
5 # Histogram of residuals
6 p_hist <- ggplot(df, aes(x = residuals)) +
7   geom_histogram(aes(y = after_stat(density)),
8     bins = 40, fill = "steelblue",
9     color = "black", alpha = 0.7) +
10   stat_function(fun = dnorm,
11     args = list(mean = mean(df$residuals),
12       sd = sd(df$residuals)),
13     color = "red", linewidth = 1)
14
15 # QQ-plot
16 p_qq <- ggplot(df, aes(sample = residuals)) +
17   stat_qq(color = "steelblue", alpha = 0.3) +
```

```

18 stat_qq_line(color = "red", linewidth = 1)
19
20 # Shapiro-Wilk test
21 set.seed(243)
22 resid_sample <- sample(df$residuals, size = 500)
23 shapiro.test(resid_sample)
24
25 # Residuals vs fitted plot
26 p_resid_fitted <- ggplot(df, aes(x = fitted, y = residuals)) +
27   geom_point(alpha = 0.3, color = "steelblue") +
28   geom_hline(yintercept = 0, color = "red",
29             linetype = "dashed") +
30   geom_smooth(method = "loess", color = "darkred")

```

Описательные статистики остатков

Показатель	Значение
Среднее	≈ 0
Стандартное отклонение	2203,53
Минимум	-5151,59
1-й квартиль	-1260,03
3-й квартиль	653,15
Максимум	13805,00

Таблица 4: Описательные статистики остатков модели

Среднее остатков близко к нулю, что соответствует свойству МНК-оценок.

Проверка нормальности остатков




Рис. 3: QQ-plot остатков модели




Рис. 4: Гистограмма остатков с наложенной кривой нормального распределения

Формальный тест Шапиро–Уилка (на подвыборке 500 наблюдений) даёт $W = 0,882$, $p < 0,001$ — нулевая гипотеза о нормальности **отвергается**.

Визуальный анализ подтверждает этот вывод:

- На QQ-plot (рис. 3) точки систематически отклоняются от теоретической прямой на обоих хвостах: правый хвост «задирается» вверх, левый — вниз. Это указывает на распределение с тяжёлыми хвостами.
- На гистограмме (рис. 4) видно, что распределение остатков имеет острый пик и длинный правый хвост. Значительная доля остатков лежит в диапазоне $[-2000; 2000]$, но есть единичные выбросы до 13 805 DM.

Проверка линейности связи




Рис. 5: График остатков vs предсказанных значений

На графике остатков против предсказанных значений (рис. 5) видно:

- Красная сглаживающая линия (LOESS) при больших предсказанных значениях (5000–10 000 DM) отклоняется от нулевой горизонтали. Это может указывать на нелинейность связи.
- Разброс остатков увеличивается с ростом предсказанных значений — характерный паттерн «веера». Это означает, что для больших сумм кредита модель даёт менее точные предсказания.

Вывод о разумности предположений

1. **Предположение о нормальности ошибок** формально нарушено (Шапиро–Уилк: $p < 0,001$). Однако при большом объёме выборки ($n = 1000$) благодаря Центральной Предельной Теореме оценки коэффициентов остаются состоятельными, а t -тесты — приближённо корректными. Нарушение нормальности влияет прежде всего на точность прогнозных интервалов для индивидуальных значений, но не на состоятельность оценок коэффициентов.

2. **Предположение о линейности** выполняется лишь приближённо. График остатков показывает, что при больших суммах кредита линейная модель может систематически недооценивать или переоценивать сумму. Это указывает на то, что в реальности связь между сроком и суммой кредита может быть не строго линейной (например, банк может иметь верхние ограничения по сумме, не зависящие от срока).
3. **Возрастающий разброс остатков** при больших значениях — наиболее заметное нарушение. Это означает, что доверительные интервалы для прогнозов на краях диапазона (очень большие или очень маленькие сроки) могут быть менее надёжными.

Ограничения интерпретации

Перечисленные нарушения накладывают следующие ограничения:

- Модель **пригодна для описания общего тренда**: срок кредита действительно положительно связан с суммой, и этот вывод устойчив.
- **Не следует чрезмерно полагаться на точные значения p -value** и доверительных интервалов, особенно для прогнозов на краях диапазона.
- Модель объясняет лишь 39% вариации — это означает, что **61% вариации сумм кредита остаётся необъяснённым**. Для практического использования в кредитном скоринге необходимо включать в модель дополнительные предикторы (статус счетов, цель кредита, кредитную историю).

Заключение

В ходе данного этапа исследования была построена модель простой линейной регрессии, связывающая сумму кредита со сроком кредита. Ключевые выводы:

1. Срок кредита является значимым предиктором суммы кредита ($\hat{\beta}_1 = 146,30$, $p < 0,001$) и объясняет 39% её вариации.
2. Связь между сроком и суммой положительна: каждый дополнительный месяц срока увеличивает ожидаемую сумму кредита примерно на 146 DM.
3. Срок кредита не заменяет финансовые переменные, а дополняет их: оба фактора вносят вклад в объяснение суммы кредита.
4. Предположения модели (нормальность ошибок, постоянство дисперсии) нарушены, что типично для финансовых данных. Модель пригодна для описания тренда, но для строгих статистических выводов требуются дополнительные методы.
5. Результаты согласуются с выводами предыдущих этапов: финансовое положение заёмщика и характеристики кредитного продукта совместно определяют сумму кредита.

Список литературы

- [1] UCI Machine Learning Repository. German Credit Data. [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit+data\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data))
- [2] Hofmann, H. (1994). Statlog (German Credit Data) Dataset. UCI Machine Learning Repository.