

Анализ кредитного риска заёмщиков

Независимый аналитический проект

Сibaкин Геopгий

Data Science & Risk Analytics Portfolio

6 октября 2026 г.

Основной вопрос

Влияет ли финансовое положение заёмщика на сумму выдаваемого кредита и уровень кредитного риска?

Уточняющие подвопросы:

- 1 Различаются ли суммы кредитов у заёмщиков с разным финансовым положением?
- 2 Связан ли статус финансового положения с вероятностью дефолта?
- 3 Какие финансовые переменные наиболее информативны для прогнозирования риска?
- 4 Как срок кредита связан с его суммой и кредитным риском?

Целевая популяция: все потенциальные заёмщики, подающие заявки на потребительский кредит.

Источник: German Credit Data (UCI Machine Learning Repository, Hans Hofmann, 1994)

Характеристики:

- **Объём:** 1000 заявок
- **Переменных:** 21 атрибут + 1 целевая
- **Период:** 1970–1975 гг.
- **Пропуски:** отсутствуют

Метод выборки:

Выборка по удобству (convenience sampling)

- Данные одного конкретного банка
- Не является вероятностной выборкой
- Высокая реалистичность (фактические исходы)
- Широкая используемость как бенчмарк

Ограничения и потенциальные ошибки

Ограничения выборки:

- Специфичность банка $\Rightarrow$ специфическая клиентура
- Временное смещение (экономика 1970-х $\neq$ современность)
- Отсутствие стратификации по демографии

Потенциальные ошибки:

- **Систематическая ошибка отбора:** недопредставленность рискованных заёмщиков из-за строгой политики банка
- **Ошибка измерения:** субъективность оценки кредитной истории клерками
- **Смещение выжившего:** в данных только одобренные заявки

Важно

Все ограничения явно учтены при интерпретации статистических результатов

Кодбук ключевых переменных

Переменная	Тип	Описание
credit_amount	Колич.	Сумма кредита в DM
duration	Колич.	Срок кредита в месяцах
credit_risk	Бинарная	Хороший / Плохой (дефолт)
status_checking	Катег.	Статус чекового счёта (4 уровня)
savings_status	Катег.	Статус сберегательного счёта (5 уровней)
own_telephone	Бинарная	Наличие телефона: да / нет

Полный датасет содержит 21 переменную: финансовые, демографические и социальные атрибуты

Процесс предобработки данных

Этапы очистки:

- Переименование переменных для единообразия
- Преобразование факторов (задание уровней и меток)
- Проверка на пропущенные значения

Пропущенные значения:

$$\sum_{i=1}^{1000} \text{is.na}(x_i) = 0$$

Важное замечание

Полное отсутствие пропусков может указывать на смещение выжившего: “неудобные” заявки с неполной информацией могли быть отфильтрованы на этапе сбора данных банком.

Показатель	Значение
Среднее	3271,26 DM
Медиана	2320,00 DM
Ст. отклонение	2822,74 DM
Минимум	250 DM
Максимум	18424 DM
Q_1	1366 DM
Q_3	3972 DM
IQR	2606 DM

Ключевые наблюдения:

- **Правосторонняя асимметрия:** среднее $>$ медиана на 41 %
- **Большой разброс:** SD составляет 86% от среднего
- **Устойчивость:** медиана менее чувствительна к экстремальным значениям

Типично для финансовых данных: большинство кредитов умеренные, но есть единичные крупные заявки.


Показатель	Значение
Среднее	20,90 мес.
Медиана	18,00 мес.
Ст. отклонение	12,06 мес.
Минимум	4 мес.
Максимум	72 мес.
Q_1	12 мес.
Q_3	24 мес.
IQR	12 мес.

Ключевые наблюдения:


- **Правосторонняя асимметрия:**
среднее $>$ медиана на 16%
- **Круглые квантили:** 12 и 24 мес.
— стандартные банковские продукты
- **Дискретность:** переменная принимает только определённые значения

Половина кредитов выдаётся на срок до 1,5 лет, половина — более 1,5 лет.

Визуализация распределений: Гистограммы



Сумма кредита (18 бинов)



Срок кредита (бины по 6 мес.)


Выбор ширины бинов: правило Фридмана–Диакониса дало 35 и 29 бинов, но мы уменьшили их количество до 18 и 12 для сглаживания шума и лучшей интерпретируемости.

Наблюдения:

- Сумма: выраженный пик 1000–2000 DM, длинный правый хвост.
- Срок: модальная структура (пики для 12, 18, 24, 48 мес.).


Визуализация: Boxplot и Violin plot

Boxplot: Сумма кредита



Boxplot: Сумма кредита

Violin plot: Сумма кредита



Violin plot: Сумма кредита

Boxplot:

- Медиана ближе к Q_1 — подтверждение асимметрии.
- Верхний ус длиннее нижнего — наличие выбросов (8000–18000 DM).

Violin plot: широкая часть внизу (1000–3000 DM) и узкий хвост сверху визуализируют плотность распределения, подтверждая правостороннюю асимметрию.

Правило $1,5 \times \text{IQR}$:

$$[Q_1 - 1,5 \cdot \text{IQR}; \quad Q_3 + 1,5 \cdot \text{IQR}] = [-2543; \quad 7881] \text{ DM}$$

Количество выбросов: 72 наблюдения (7,2% выборки).

Показатель	До удаления	После удаления
Среднее	3271,26	2676,26
Медиана	2320,00	2145,50

Ключевой вывод


Медиана устойчивее среднего: среднее изменилось на 18,2%, медиана — лишь на 7,5%. Для асимметричных финансовых распределений медиана — более надёжная мера центральной тенденции.

Анализ по группам: Сумма кредита

Группа	n	Среднее	Медиана	SD
Хороший	700	2985	2244	2401
Плохой	300	3938	2574	3536

Различия:

- Средние: +32% (953 DM)
- Медианы: +15% (330 DM)
- Разброс: SD в 1,5 раза больше



Наблюдение


“Плохие” заёмщики берут бóльшие суммы с бóльшим разбросом — возможно, пытаются покрыть финансовые трудности за счёт более крупных займов.

Анализ по группам: Срок кредита

Группа	<i>n</i>	Среднее	Медиана	SD
Хороший	700	19,2	18	11,1
Плохой	300	24,9	24	13,3

Различия:

- Средние: +30% (5,7 мес.)
- Медианы: +33% (6 мес.)
- IQR: 24 vs 12 мес. (в 2 раза больше)



Наблюдение

“Плохие” заёмщики берут кредиты на большие сроки — это увеличивает неопределённость и риск дефолта на длительном горизонте.

Проверка гипотез: Доверительные интервалы

95% ДИ для среднего суммы кредита:

$$\bar{x} \pm t_{0,025; 999} \cdot SE = 3271,26 \pm 1,9623 \cdot 89,26 = [3096,09; 3446,42]$$

Обоснование t -распределения: генеральное σ неизвестно, оцениваем через выборочное s .

Уровень	$t_{\alpha/2}$	Границы ДИ	Ширина
90%	1,6464	[3124,30; 3418,22]	293,92
95%	1,9623	[3096,09; 3446,42]	350,33
99%	2,5808	[3040,89; 3501,62]	460,73

Фундаментальный компромисс: чем выше уверенность в покрытии истинного параметра, тем шире интервал (ниже точность).

Доверительный интервал для доли

Переменная: Наличие телефона (own_telephone)

- Объем выборки: $n = 1000$
- Количество с телефоном: $k = 404$
- Выборочная доля: $\hat{p} = 0,4040$ (40,40%)
- Стандартная ошибка: $SE_{\hat{p}} = 0,0155$

95% ДИ для генеральной доли:

$$\hat{p} \pm z_{0,025} \cdot SE_{\hat{p}} = 0,4040 \pm 1,96 \cdot 0,0155 = [0,3736; 0,4344]$$

Интерпретация

Мы на 95% уверены, что истинная доля заёмщиков с телефоном лежит в диапазоне от 37,36% до 43,44%. В 1970-х годах наличие телефона было важным маркером финансовой стабильности.

Сравнение средних в двух группах

Группа	n	$\bar{x}$, DM	s , DM	95% ДИ
Хороший риск	700	2985,46	2401,47	[2807,25; 3163,67]
Плохой риск	300	3938,13	3535,82	[3536,39; 4339,86]

Анализ пересечения:

- Интервалы **не пересекаются** ($3163,67 < 3536,39$).
- Зазор между интервалами составляет 373 DM.

Вывод

Непересечение 95% ДИ — достаточное условие значимости различий.
“Плохие” заёмщики берут статистически значимо большие суммы.

Дисперсионный анализ ANOVA

Вопрос: Влияет ли статус чекового счёта на сумму кредита?

Гипотезы

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$$

H_1 : хотя бы одно μ_i отличается

Проверка предпосылок:

- Нормальность (Шапиро–Уилк): $p < 0,001$ (формально нарушена)
- Гомогенность (Бартлетт): $p < 0,001$ (формально нарушена)
- При $n = 1000$ ANOVA робастен благодаря ЦПТ.

Результаты: $F(3, 996) = 7,186$, $p = 8,95 \times 10^{-5} < 0,05$

Решение: ОТВЕРГАЕМ H_0

Размер эффекта: $\eta^2 = 0,0212$ (малый эффект, объясняет 2,1% дисперсии).

Вопрос: Существует ли связь между статусом счёта и кредитным риском?

Статус счёта	% Хороший	% Плохой
Отрицательный (< 0)	50,73	49,27
Малый ($0 \leq X < 200$)	60,97	39,03
Высокий (≥ 200)	77,78	22,22
Нет счёта	88,32	11,68

Результаты:

- $\chi^2(3) = 123,72, p < 2,2 \times 10^{-16}$
- **Гипотеза о независимости ОТВЕРГАЕТСЯ**
- Разница в доле дефолтов: **37,59** п.п.


Клиенты с отрицательным балансом имеют почти в 4 раза больший риск дефолта по сравнению с клиентами без счёта.

Регрессионный анализ: Модель

Модель: $\text{credit_amount} = \beta_0 + \beta_1 \cdot \text{duration} + \varepsilon$

Коэфф.	Оценка	<i>t</i>	<i>p</i>
β_0	213,22	1,53	0,127
β_1	146,30	25,29	< 0,001

- $R^2 = 0,39$ (39% дисперсии)
- $F = 639,69$, $p < 0,001$
- +1 месяц $\Rightarrow$ +146 DM




Scatterplot с линией регрессии

Интерпретация:

- Свободный член незначим ($p = 0,127$) — кредит с нулевым сроком не имеет смысла.
- Коэффициент при сроке значим: каждый дополнительный месяц увеличивает ожидаемую сумму на 146 DM.

Регрессионный анализ: Различия по группам риска



Scatterplot с разделением по группам риска

Наблюдения:


- Линии регрессии для “Хороших” и “Плохих” заёмщиков **практически параллельны**.
- Линия для “Плохих” **смещена вверх**.
- При том же сроке кредита “Плохие” заёмщики берут **большие суммы**.

Интерпретация:

- Это согласуется с выводами предыдущих этапов анализа.
- Срок кредита и кредитный риск — **независимые факторы**, совместно влияющие на сумму.


Регрессионный анализ: Проверка предположений

QQ-plot остатков модели



QQ-plot остатков

График остатков: остатки vs предсказанные значения



Остатки vs предсказанные значения

Проверка нормальности остатков:

- Тест Шапиро–Уилка: $W = 0,882$, $p < 0,001$.
- На QQ-plot точки отклоняются от прямой на хвостах.
- **Нормальность формально нарушена.**


Проверка постоянства дисперсии:

- На графике “остатки vs fitted” разброс **увеличивается** с ростом предсказанных значений (клинообразная форма).

Регрессионный анализ: Распределение остатков

Гистограмма остатков модели

С наложенной кривой нормального распределения



Гистограмма остатков с нормальной кривой

Описательные статистики остатков:

- Среднее: ≈ 0 (свойство МНК)
- Ст. отклонение: 2203,53 DM
- Минимум: -5151,59 DM
- Максимум: 13805,00 DM

Форма распределения:

- Острый пик и длинный правый хвост.
- Наличие единичных выбросов до 13805 DM.

Согласованность результатов

Статистическая vs практическая значимость:

- Статус счёта значим статистически ($p < 0,001$), но эффект мал ($\eta^2 = 2,1\%$).
- Срок кредита объясняет 39% дисперсии — вклад существенно выше.
- Оба фактора вносят независимый вклад в модель.

Согласованность методов:

- Непересечение 95% ДИ для групп риска $\Leftrightarrow p < 0,05$ в формальных тестах.
- Визуальный анализ (boxplot) полностью подтверждает результаты формальных тестов.

Ключевой вывод

Характеристики кредитного продукта (срок) сильнее связаны с суммой, чем финансовое положение, но оба фактора критически важны для скоринга.

Ограничения исследования

Данные:

- Выборка по удобству (один банк, 1970-е)
- Смещение выжившего (только одобренные заявки)
- Временное смещение

Статистические:

- Нарушение предположений (асимметрия, нормальность)
- Выбросы (7–7,2%)
- Несбалансированность классов (70% vs 30%)

Модель:

- $R^2 = 0,39$ — объясняет лишь 39% вариации
- Не включены важные предикторы (цель кредита, полная кредитная история)

Обобщаемость:

- Результаты требуют осторожной экстраполяции на современные условия

Важно

Все ограничения явно учтены при интерпретации. Результаты служат основой для гипотез, а не окончательными бизнес-решениями.

Банковский скоринг и риск-менеджмент:

- **Сегментация клиентов:** заёмщики с отрицательным балансом чекового счёта требуют дополнительных проверок.
- **Политика одобрения:** клиенты без чекового счёта имеют наименьшую долю дефолтов (11,7%).
- **Ценообразование:** дифференциация процентных ставок в зависимости от статуса счёта.
- **Управление рисками:** срок кредита может использоваться как инструмент балансировки риска.

Рекомендации:

- Использовать статус чекового счёта как один из ключевых предикторов (но не единственный).
- Учитывать срок кредита при оценке запрашиваемой суммы.

- 1 **Распределения асимметричны** (правосторонняя асимметрия), медиана устойчивее среднего.
- 2 **Выбросы составляют 7–7,2%** наблюдений и существенно влияют на среднее значение.
- 3 **Кредитный риск связан с параметрами кредита:** “плохие” заёмщики берут бóльшие суммы на бóльшие сроки.
- 4 **Статус чекового счёта значимо влияет на сумму** ($p < 0,001$), но эффект мал ($\eta^2 = 2,1\%$).
- 5 **Статус счёта сильно связан с риском:** разница в доле дефолтов 37,59 п.п. между крайними группами.
- 6 **Срок кредита — значимый предиктор суммы** ($R^2 = 0,39$): +1 месяц $\Rightarrow$ +146 DM.

Финансовые переменные — ценные предикторы, но должны использоваться в комбинации с другими признаками для построения надёжных моделей.

Спасибо за внимание!

Готов подробно обсудить методологию, проверку предположений и бизнес-интерпретацию результатов.

Контакты и материалы проекта

- **GitHub репозиторий с кодом и отчетом:** github.com/HelloImWebbieeee/credit-risk-analysis
- **Email:** gekosibakin@edu.hse.ru
- **Telegram:** @webbiey

Сibaкин Георгий | Data Science & Risk Analytics Portfolio